

Orynode PDF 长样例 (文本层)

本长文档用于评测切分与页码绑定，内容刻意重复铺陈，但保留唯一锚点句。

第 1 段。严格离线知识库在导入后于本机完成解析、索引、检索与回答。用户资料不得因问答路径离开设备。长文档切分后仍按文档序保留页码绑定。切分页码绑定不得漂移。

第 2 段。索引过程允许分批 checkpoint；未 publish 的分片对检索不可见。同一 content hash 的文档去重，避免重复入库。

第 3 段。混合检索结合向量相似度与全文检索。本长样例不改融合权重，只提供可引用原文。

第 4 段。引用必须来自封闭集合中的资料片段。证据不足时应拒答，而不是用通识补全。

第 5 段。PDF 文本层抽取失败且 OCR 仍无有效文字时，导入阶段必须明确失败，不得生成空索引。

第 6 段。容量按 chunk 计数，而不是按文件个数。设备内存压力下仍应保持可取消与可恢复。

第 7 段。预览跳转应尽量落到页码或原文片段附近，但不保证复杂版式下的像素级高亮。

第 8 段。本段为填充：离线、本机、沙箱、索引、检索、拒答、引用、页码、切分、embedding。

第 9 段。本段为填充：私人知识库、本地知识库、知识库在本文中同指本机资料索引。

第 10 段。本段为填充：不要因为 seed 试跑结果去单独下调拒答阈值或改写融合公式。

第 11 段。本段为填充：长文档应能被多轮提问反复引用，定位仍以入库页序为准。

第 12 段。本段为填充：若用户中断索引，恢复时不得要求重新选择原始文件。

第 13 段。本段复述加固：切分页码绑定不得漂移（与第 1 段同锚，便于长文召回）。

第 14 段。收尾：以上内容仅供 evalset 使用，可公开提交到仓库。